

Практичне завдання

Дослідження та очищення даних за допомогою Python та Pandas

У реальних Data Science-проектах більшість часу витрачається не на побудову моделей, а на підготовку даних. Саме тому сьогодні ви познайомитеся з одним із найважливіших етапів Data Science pipeline — **Exploratory Data Analysis (EDA)**.

Ваше завдання — дослідити реальний набір даних, оцінити його якість, підготувати до подальшого аналізу та зробити перші висновки.

Частина 1: Підготовка середовища

Перед початком роботи переконайтеся, що у вас встановлено:

- Python 3.11+;
- Google Chrome;
- Jupyter Notebook;
- Pandas;
- NumPy;
- Matplotlib;
- Seaborn.

Перевірте, що середовище готове до роботи.

None

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

print("Environment is ready!")
```

Частина 2: Завантаження та первинний огляд даних

[Отримати датасет](#)

1. Завантажте CSV-файл у DataFrame за допомогою Pandas.
2. Проведіть первинний аналіз датасету:
 - перегляньте перші рядки (`head()`);
 - перевірте розмір датасету (`shape`);
 - дослідіть інформацію про стовпці (`info()`);
 - перегляньте базову статистику (`describe()`).

Дайте відповіді на питання:

- Скільки записів містить датасет?
- Які типи даних використовуються?
- Які перші спостереження можна зробити після роботи з даними?

Частина 3: Дослідження якості даних

Перевірте датасет на наявність:

- пропущених значень;
- дублікатів;
- некоректних типів даних;
- аномальних або підозрілих значень.

Наприклад, зверніть увагу на ситуації, коли: вік людини дорівнює -5, дохід дорівнює 0 там, де цього не може бути, дата має неправильний формат, категорія записана різними способами ("Male", "male", "M") тощо

Для пошуку проблем можуть знадобитися:

- `isna()`
- `duplicated()`
- `value_counts()`
- `unique()`
- `describe()`

Дайте відповіді на питання:

- Які проблеми вдалося знайти?

- Які з них можуть вплинути на результати аналізу?

Частина 4: Очищення даних

Виконайте очищення датасету.

За необхідності:

- обробіть пропущені значення;
- видаліть дублікати;
- виправте типи даних;
- скоригуйте або видаліть аномальні значення.

Після очищення ще раз перевірте структуру датасету.

Частина 5: Базовий аналіз

Для числових ознак побудуйте базові статистики:

- середнє значення;
- медіану;
- мінімальне значення;
- максимальне значення.

Обговорення

- Які показники вас найбільше здивували?
- Які характеристики даних можна визначити вже на цьому етапі?
- Чи сильно відрізняються середнє та медіана?
- Чи може це свідчити про наявність викидів?
- Які ознаки мають найбільший розкид?

Частина 6: Візуалізація

Побудуйте **щонайменше 2–3 графіки**, які допоможуть краще зрозуміти дані.
Наприклад: гістограма, boxplot, bar chart, scatter plot.

Гарний графік має відповідати на конкретне питання.

Вимоги: кожен графік повинен містити: заголовок, підписані осі, читабельне оформлення.

Частина 7: Аналітичні висновки

Підготуйте **3–5 висновків**, які вдалося зробити після аналізу даних.

Наприклад:

- які особливості містить датасет;
- які закономірності вдалося знайти;
- які дані можуть потребувати додаткового дослідження.

Намагайтеся не описувати графіки:

 На графіку видно багато синіх стовпчиків.

 Більшість об'єктів належать до однієї категорії, що може свідчити про незбалансованість вибірки.

 Середнє дорівнює 15.

 Значне розходження між середнім та медіаною може свідчити про наявність викидів.

Частина 8: Підсумок роботи

Наприкінці підготуйте короткий опис (до 1 сторінки), у якому зазначте:

- які проблеми були знайдені;
- які методи очищення ви використали;
- які основні висновки вдалося отримати;
- які питання залишилися відкритими;
- які додаткові дослідження можна провести над цими даними.



Бонусне завдання

Якщо завершите основну частину раніше:

- знайдіть найсильніші кореляції між числовими змінними;
- побудуйте теплову карту (heatmap);
- запропонуйте одну гіпотезу, яку можна перевірити на основі цього датасету.