


20-24 Липня 2026

Data Science School 2026



Дмитро
Лукашов

Applied Scientist
Squad



Що ж таке UMAP?

День 2: 21.07.26

UMAP повністю зберігає топологічну структуру ріманівського многовиду з якого засемплені дані виражену 1,2-симплексами та апроксимує симплекси вищого порядку ймовірностями. При проекції в 2 або 3 вимірну візуалізацію UMAP спирається на мінімізацію втраченої інформації

Топологічний простір

(S, τ_S)

Множина

Колекція «відкритих» множин

$$\{U_\alpha\}_{\alpha \in A} \subseteq \tau_S, \bigcup_{\alpha \in A} U_\alpha \in \tau_S$$

$$\{U_i\}_{i=1}^n \subseteq \tau_S, \bigcap_{i=1}^n U_i \in \tau_S$$

$$\emptyset \in \tau_S$$

$$S \in \tau_S$$


$$\forall U \in \tau_S, U \subseteq S$$

$f: S \rightarrow Y$ неперервна якщо і тільки якщо
 $\forall V \in \tau_Y, f^{-1}(V) \in \tau_S$

Топологічний МНОГОВИД

$\mathcal{M}$

$\forall p, q \in \mathcal{M}$, якщо $p \neq q$, то $\exists U_p, U_q \in \tau_{\mathcal{M}}$, такі що $p \in U_p, q \in U_q$ та $U_p \cap U_q = \emptyset$




$\exists \mathcal{B} \subseteq \tau_{\mathcal{M}}, \mathcal{B}$ зліченна підколекція та $\forall U \in \tau_{\mathcal{M}},$

$$\exists A \subseteq \mathcal{B} \text{ таке що } U = \bigcup_{U_b \in A} U_b$$

Друга аксіома зліченності



$\forall p \in \mathcal{M}, \exists \phi: U_p \rightarrow \mathbb{R}^n$ така, що
 ϕ — неперервна бієкція
та ϕ^{-1} — теж неперервна



(U, ϕ) — мапа


ϕ_b — мапа, що відповідає $U_b \in \mathcal{B}$,

$(\mathcal{M}, \{\phi_b\})$ — атлас

Гладкий многовид

$$\psi_{pq}: \mathbb{R}^n \rightarrow \mathbb{R}^m = \phi_q \circ \phi_p^{-1}$$


$$\forall U_p, U_q \in \tau_{\mathcal{M}}, \psi_{pq} \in C^\infty \left\{ \rightarrow \exists \right\}$$



$$J[\psi_{pq}] = \begin{pmatrix} \frac{\partial \phi_p^1}{\partial \phi_q^1} & \cdots & \frac{\partial \phi_p^1}{\partial \phi_q^m} \\ \vdots & \ddots & \vdots \\ \frac{\partial \phi_p^n}{\partial \phi_q^1} & \cdots & \frac{\partial \phi_p^n}{\partial \phi_q^m} \end{pmatrix}$$

$$\phi_p(x) = \left(\phi_p^1(x), \dots, \phi_p^n(x) \right)^T$$

Многовид Рімана




$$\gamma: [0,1] \rightarrow \mathcal{M}$$

$$L(\gamma) = \int_0^1 \|\dot{\gamma}(t)\| dt$$

$$\dot{\gamma}(t) = \lim_{\Delta t \rightarrow 0} \frac{\gamma(t + \Delta t) - \gamma(t)}{\Delta t}$$

Four red question marks are drawn above the expression $\gamma(t + \Delta t) - \gamma(t)$, which is also underlined in red.



$$\dot{\gamma}(t)[\phi_{\gamma(t)}] = \frac{d}{dt} \phi_{\gamma(t)}(\gamma(t)) = \lim_{\Delta t \rightarrow 0} \frac{\phi_{\gamma(t)}(\gamma(t + \Delta t)) - \phi_{\gamma(t)}(\gamma(t))}{\Delta t}$$

$$\dot{\gamma}(t)[\phi_{\gamma(t)}]: [0,1] \rightarrow T_p \mathcal{M}$$

$$\|\dot{\gamma}(t)[\phi_{\gamma(t)}]\| = \sqrt{\dot{\gamma}(t)[\phi_{\gamma(t)}] \cdot \dot{\gamma}(t)[\phi_{\gamma(t)}]} = \sqrt{g_{\gamma(t)}(\dot{\gamma}(t), \dot{\gamma}(t))}$$


$$g_{\gamma(t)} = I_{n \times n} \text{ для } \mathbb{R}^n$$


$$g_p: T_p \mathcal{M} \times T_p \mathcal{M} \rightarrow \mathbb{R}_+$$

$$p = \gamma(t)$$

$$p \in U_p \in \mathcal{B}$$

$$L(\gamma) = \int_0^1 \sqrt{g_{\gamma(t)}(\dot{\gamma}(t), \dot{\gamma}(t))} dt$$





$\gamma(t)$


$$\dot{\gamma}(t) [\phi_{U_p}], g_{U_p}$$

$$\dot{\gamma}(t) [\phi_{U_q}], g_{U_q}$$

$$g_{\gamma(t)}[\phi_{U_q}] = J^T g_{\gamma(t)}[\phi_{U_p}]^J !$$

$$d_{\mathcal{M}}(p, q) = \inf_{\gamma} L(\gamma)$$

Від неперервного до дискретного



То

Гарне покриття

Нехай

$$I = \{1, 2, \dots, N\}$$

$$\{p_i\}_{i \in I} \in \mathcal{M}$$

$$\{U_i\}_{i \in I} \subseteq \mathcal{M}$$

$$p_i \in U_i$$

$$\sigma_n = \{a \subseteq I : |a| = n\}$$

σ_1 — вершини графу

σ_2 — ребра графу

Якщо

$$\bigcup_{i \in I} U_i = \mathcal{M}$$

$$\forall \sigma_n, \bigcap_{i \in \sigma_n} U_i \neq \emptyset \text{ — стягувана}$$

Теорема про нерв


Якщо для U існує така неперервна функція та точка $p_0 \in U$, що

$$H(U, 0) = U$$

$$H(U, 1) = p_0$$

То U – стягувана множина

Нервова система покриття



Приклад з двома точками

Теорема опуклих стягуваних множин

Якщо множина опукла, то вона стягувана

Перетин довільної кількості опуклих множин – опукла множина

UMAP, enfin

Припущення

$\mathcal{M}$

$$\mathcal{X} = \{p_1, p_2, \dots, p_N\}, p_i \in \mathcal{M}$$

$$K \subseteq \mathcal{X}, |K| = k, K \subseteq U_p$$

$$U_p \cap \mathcal{X} = K$$

$$\rho_{\mathcal{M}}(p) = \frac{k}{\int_{U_p} \sqrt{\det(g_p)} d\phi_1 \dots d\phi_n} = C$$

Спостереження

$$X = \{\phi_p(p) : p \in \mathcal{X}\}$$

$$K \subseteq X, |K| = k, K \subseteq B_n(x)$$

$$B_n(x) \cap X = K$$

$$r_x = \max_{x, y \in K} \frac{d_{\mathcal{M}}(x, y)}{2}$$

$$g_x = I_{n \times n}$$

$$\rho_{\mathcal{M}}(x) = \frac{k}{V_n(r_x)} \neq C$$

Висновок та fix

$$g_x \neq I_{n \times n}$$

$$g_x \stackrel{!}{=} \frac{1}{\sigma_x^2} I_{n \times n} \quad \left| \int_{B(r_x)} \sqrt{\det(g_x)} d\phi_1 \dots d\phi_n = \int_{B(r_x)} \frac{1}{\sigma_x} d\phi_1 \dots d\phi_n = \frac{1}{\sigma_x} V_n(r_x) \right.$$

$$\rho_{\mathcal{M}}(x) = \frac{\sigma_x k}{V_n(r_x)} = C \rightarrow \boxed{\sigma_x} = \frac{\boxed{C} V_n(r_x)}{k}$$

Емпіричні вимоги


1. Найближчі дві точки завжди з'єднані
2. Точки далі від найближчої мають «вагу» у проміжку $[0,1)$ щоб компенсувати втрату k -симплексів вище другого

$$p_{y|x} = \exp\left(-\frac{d_{\mathcal{M}}(x, y) - c_x}{\sigma_x}\right)$$

$$c_x = \min_{y \in X} d_{\mathcal{M}}(x, y)$$

$$\sum_{y \in X \setminus \{x\}} p_{y|x} = \log_2(k)$$

Метричний
тензор без σ_x



$$p_{xy} = p_{y|x} + p_{x|y} - p_{y|x}p_{x|y}$$

$$q_{f_{\theta}(x)f_{\theta}(y)} = \left(1 + a||f_{\theta}(x) - f_{\theta}(y)||^{2b}\right)^{-1}$$

$$\Psi(d) = \begin{cases} 1, d \leq \text{min distance} \\ \exp\left(\frac{-(d - \text{min distance})}{\text{spread}}\right), d > \text{min distance} \end{cases}$$

$$\operatorname{argmin}_{a,b} \sum_d ((1 + ad^{2b})^{-1} - \Psi(d))$$

$$d \in [0,3 \cdot \text{spread}]$$

$$\operatorname{argmin}_{\theta} H(P_{xy}, Q_{f_{\theta}(x)f_{\theta}(y)})$$



**Дякую
за увагу**