

Практичне завдання Алгоритми класифікації та регресії

Мета: засвоїти основні відомості про роботу з алгоритмами класифікації та регресії та робота з різними наборами даних.

Частина 1. Підготовка даних

- Завантажити дані згідно з варіантом.
- Розділити на тренувальну, валідаційну та тестові вибірки в пропорції 70/15/15
- За потреби обробити NaN значення – або видаленням, або заповненням середнім, або якимось іншим чином. Обраний варіант обґрунтувати.
- Нормалізувати дані – для тренувальних даних обрахувати значення mean(середнього) та standard deviation(стандартного відхилення) для кожної з ознак і перетворити дані віднявши обраховане середнє та поділивши на стандартне відхилення.
- Нормалізувати валідаційні та тестові даних на основі обрахованих mean та std для тренувальних даних.

Частина 2. Побудова дерева рішень

- Побудувати 3 різні дерева рішень(Decision tree) з різною глибиною на основі даних згідно з варіантом.
- Візуалізувати отримані дерева рішень. Порівняти точність отриманих дерев рішень на валідаційній та тренувальній вибірках.
- Порахувати метрики, які відповідають задачі
- * Візуалізувати результати класифікації/регресії на тестовому сеті

Частина 3. Побудова k-nn

- Побудувати 3 різні k-nn моделі з різним k на основі даних згідно з варіантом.

- b. Порахувати метрики, які відповідають задачі
- c. * Візуалізувати результати класифікації/регресії на тестовому сеті

Частина 4. Побудова **logistic regression** (для варіантів з класифікацією)

- a. Побудувати базову модель на основі даних згідно з варіантом.
- b. Порахувати метрики для класифікації
- c. * Візуалізувати результати класифікації/регресії на тестовому сеті

Частина 5. Побудова **polynomial regression** (для варіантів з регресією)

- d. Побудувати 3 різні моделі з різними степенями полінома на основі даних згідно з варіантом.
- e. Порахувати метрики для регресії
- f. * Візуалізувати результати класифікації/регресії на тестовому сеті

Частина 6. * Побудова випадкового лісу (**random forest**)

- g. Побудувати 3 різні моделі з 3 різними кількостями дерев на основі даних згідно з варіантом.
- h. Порахувати метрики, які відповідають задачі
- i. * Візуалізувати результати класифікації/регресії на тестовому сеті

Частина 7. Кінцева валідація

- a. Порівняти метрики, запропонувати варіанти покращення кожного з методів



Приклад створення тренування Дерева прийняття рішень

<https://jakevdp.github.io/PythonDataScienceHandbook/05.08-random-forests.html>

Джерело для завантаження датасетів:

<https://www.kaggle.com/datasets/abdoomoh/all-seaborn-built-in-datasets>

* Завдання з зірочкою - підвищений рівень складності

Варіант обирайте за останньою цифрою дня народження, на вибір є два датасети.

Варіант	Датасет	Тип	Цільовий стовпчик	Коментарі до завдання

0	anagrams.csv	Classification	subid or attnd	Predict subject/attention state based on memory recall scores.
1	attention.csv	Classification	attention	Predict attention condition (e.g., focused vs. divided) from reaction scores.
2	brain_networks.csv	Classification	network	Multi-class fMRI signal classification across brain network regions.
3	car_crashes.csv	Regression	total	Predict total fatal car crashes per billion miles driven.
4	diamonds.csv	Regression	price	Predict diamond price based on carat, cut, color, clarity, and dimensions.
5	dots.csv	Regression	firing_rate	Predict neural firing rate from motion coherence and alignment time.
6	dowjones.csv	Regression	Price	Time-series forecasting of the Dow Jones Index value over time.

7	exercise.csv	Regression	pulse	Predict heart rate based on diet type, rest time, and activity intensity.
8	flights.csv	Regression	passengers	Time-series prediction of monthly airline passenger totals.
9	fmri.csv	Regression	signal	Predict BOLD fMRI signal intensity based on time and brain region.
0	geyser.csv	Regression	duration (or waiting)	Predict Old Faithful geyser eruption duration or time until next eruption.
1	healthexp.csv	Regression	Life_Expectancy	Predict life expectancy based on healthcare expenditure per capita and country.
2	iris.csv	Classification	species	Classic multi-class classification (Setosa, Versicolor, Virginica).
3	mpg.csv	Regression	mpg	Predict fuel efficiency (miles per gallon) based on vehicle specs.

4	<code>penguins.csv</code>	Classification	<code>species</code>	Predict penguin species (Adelie, Chinstrap, Gentoo).
5	<code>planets.csv</code>	Classification / Regression	<code>method</code> (or <code>distance</code>)	Predict exoplanet detection method (Classification) or orbital parameters (Regression).
6	<code>seaice.csv</code>	Regression	<code>extent</code>	Time-series forecasting of Arctic sea ice extent.
7	<code>taxis.csv</code>	Regression	<code>fare</code> (or <code>tip</code>)	Predict NYC taxi trip fare or tip amount.
8	<code>tips.csv</code>	Regression	<code>tip</code>	Predict tip amount based on total bill, table size, day, and time.
9	<code>titanic.csv</code>	Classification	<code>survived</code>	Classic binary classification (survived = 1 / 0).

Питання для самоконтролю

- Яка різниця між класифікацією та регресією?
- Що таке дерева прийняття рішень?
- Що таке випадковий ліс?

- Що таке k-nn?
- Що таке логістична регресія?
- Поясніть чому на вашу думку ви отримали кращі/гірші результати на різних алгоритмах

Що потрібно здати?

Після завершення практичної роботи:

1. Заархівуйте **всю робочу директорію проєкту**.
2. Завантажте отриманий [.zip](#)-архів через форму здачі домашнього завдання.