

Комплексне контрольне завдання

Підсумувати знання, отримані під час Data Science School 2026, та продемонструвати повний цикл роботи Data Scientist: від дослідження даних і їх попередньої обробки до побудови моделей машинного навчання, кластеризації, оцінки результатів та формування висновків.

Дані

Для виконання роботи використовуйте [Bank Marketing Dataset](#)

Датасет містить:

- 11 162 рядки;
- 17 колонок;
- числові та категоріальні ознаки.

Дані описують результати телефонної маркетингової кампанії банку та містять соціально-демографічні характеристики клієнтів, історію попередніх контактів і результат кампанії.

Частина 1. Огляд та попередній аналіз даних

Необхідно:

- завантажити датасет;
- перевірити розмір та типи колонок;
- знайти пропуски, дублікати та аномальні значення;
- побудувати базову статистику;
- проаналізувати баланс цільової змінної.

Частина 2. Візуалізація даних

Побудуйте:

- розподіли ключових числових ознак;
- boxplot (або аналог) для пошуку викидів;
- heatmap кореляцій числових ознак;
- залежність цільової змінної щонайменше від **трьох** ознак;
- візуалізацію після зниження розмірності даних.

Частина 3: Попередня обробка даних

Виконайте:

- обробку пропусків та дублікатів із поясненням обраного підходу;
- кодування категоріальних ознак;
- масштабування або нормалізацію числових ознак (параметри необхідно обчислювати **лише на тренувальній вибірці**);
- feature engineering — створіть щонайменше **одну нову ознаку** та поясніть її призначення.

Частина 4. Кластеризація

Використайте один із алгоритмів:

- **K-Means**, або
- **DBSCAN**.

Якщо використовуєте K-Means:

- обґрунтуйте вибір кількості кластерів (Elbow Method або Silhouette Score).

Також необхідно:

- описати 2–3 отримані сегменти;
- перевірити, чи пов'язані кластери з цільовою змінною;

- зробити короткі висновки.

Частина 5. Побудова моделей машинного навчання

Побудуйте:

- одну **базову модель**, яка стане точкою порівняння;
- щонайменше **дві різні моделі** із запропонованих:
 - Decision Tree;
 - k-Nearest Neighbors;
 - Logistic Regression;
 - Random Forest.

Частина 6. Оцінка моделей

Необхідно:

- розділити дані на **train / validation / test**;
- обрати відповідні метрики (Accuracy, Precision, Recall, F1-score, Confusion Matrix тощо) та пояснити їх вибір;
- обґрунтувати використану схему валідації;
- оцінити, чи може випадковий K-Fold призводити до оптимістичних результатів;
- порівняти результати на validation та test вибірках і пояснити можливі відмінності.

Частина 7. Висновки

У фінальній частині коротко опишіть:

- що вдалося реалізувати;
 - які висновки можна зробити за результатами аналізу;
 - що можна було б покращити за наявності більшого часу або додаткових даних.
-

Що потрібно здати?

До здачі необхідно підготувати:

-  Jupyter Notebook ([.ipynb](#)) із повною реалізацією роботи;
-  короткий звіт із висновками (за бажанням можна оформити всередині ноутбука);
-  архів із усіма файлами проєкту (без датасету, якщо він не змінювався).

Рекомендації

- Використовуйте зрозумілі назви змінних та функцій.
- Коментуйте ключові етапи роботи.
- Пояснюйте свої рішення, особливо під час обробки даних, вибору моделей і метрик.
- Важливим є не лише отриманий результат, а й логіка його досягнення.



Критерії оцінювання (30 балів)

Критерій	Макс. балів	Що оцінюється
1. Аналіз та візуалізація даних	5	Проведено первинний аналіз даних, перевірено якість датасету, побудовано змістовні візуалізації, що допомагають зрозуміти дані та взаємозв'язки між ознаками.
2. Попередня обробка даних	5	Коректна обробка пропусків і дублікатів, кодування категоріальних ознак, масштабування даних, створення нових ознак із обґрунтуванням прийнятих рішень.
3. Кластеризація та моделювання	5	Побудовано кластеризацію та щонайменше дві моделі машинного навчання. Вибір алгоритмів і параметрів аргументований, реалізація коректна.
4. Оцінка та валідація моделей	5	Використано релевантні метрики, обґрунтовано схему валідації, проведено порівняння моделей та інтерпретацію отриманих результатів.
5. Якість коду та оформлення	5	Код структурований, читабельний та відтворюваний. Ноутбук має логічну структуру, містить пояснення ключових етапів та легко читається.

6. Висновки та аналітика	5	Висновки базуються на отриманих результатах, демонструють розуміння сильних і слабких сторін моделей, містять ідеї щодо можливих покращень.
---------------------------------	----------	---

Важливо: оцінюється не лише фінальна якість моделей, а й коректність виконання всіх етапів роботи, аргументація прийнятих рішень та здатність інтерпретувати отримані результати.